

Analyses statistiques des expériences numériques

Cours 3 : Planification d'expériences numériques

Bertrand looss

Polytech Nice Sophia

Décembre 2025



ENJEUX DE LA PLANIFICATION D'EXPERIENCES

Objectifs d'une planification d'expériences réfléchie

- ◆ **Définir un plan d'expériences** = placer les points d'expérimentation ou de simulation dans le domaine de variation des entrées
 - ⇒ **Minimiser le nb de points (expériences chères)**
 - ⇒ **Maximiser l'information collectée pour un nb de points donné**

- ◆ **Etablir les liens entre :**
 - **Réponse / sortie du code** : grandeur physique étudiée
 - **Facteurs / entrées du code** : grandeurs physiques modifiables par l'expérimentateur ou le simulateur sensées influencer sur les variations de la réponse
 - *Différente nature* : continus, discrets ou qualitatifs
 - *Domaine de variation* : [borne inf ; borne sup] ⇒ discrétisation en niveaux

Exercice


INTRODUCTION

Un plan maladroit : le plan « One-At-A-time » (OAT)

Idée naturelle, mais maladroite :

pour analyser les causes d'un phénomène, faire des expériences en **ne bougeant qu'une seule entrée à la fois**.

OAT apporte des informations, mais l'**exploration est pauvre : pourquoi ?**



INTRODUCTION


Un plan maladroit : le plan « One-At-A-time » (OAT)

Idée naturelle, mais maladroite :

pour analyser les causes d'un phénomène, faire des expériences en **ne bougeant qu'une seule entrée à la fois**.

OAT apporte des informations, mais l'**exploration est pauvre** :

- ne détecte pas les non monotonies, discontinuités, interactions
- laisse de grandes zones inexplorées dans l'espace des paramètres d'entrée : fléau de la dimension




PLANS D'EXPÉRIENCES

“La planification d’expériences peut être définie comme la stratégie pour configurer les expériences [réaliser des simulations] de telle manière que l’information requise soit obtenue aussi efficacement et aussi précisément que possible.” (Lewis & Phan-Tan-Luu, 2000)

Plans classiques (entrées discrétisées suivant des niveaux)

Exemples :

-  Plan factoriel complet 2^3
-  Plan factoriel fractionnaire 2^{3-1}



Plans classiques (entrées continues)

Plans optimaux consistant à minimiser une variance ou le déterminant d’une matrice de covariance par rapport à un modèle spécifié (linéaire, polynôme d’ordre deux, ...)

Plans pour simulations numériques : space filling designs

Spécificités

- expériences déterministes (erreur=0),
- grand nombre d’entrées (continues, catégorielles),
- larges domaines de variation,
- variables d’intérêt multiples,
- modèles fortement non linéaires, ...

Biblio : Kleijnen (1970), McKay (1979), Morris(1995), ...

Biblio : Fisher (1917), Box et Wilson (1954), Taguchi (1960), Mitchell (1958), ...

CURIOSITÉS DE LA MONTÉE EN DIMENSION



Illustration du fléau de la dimension (*curse of dimensionality*)

Volume du cube de côté c en dimension p : c^p

Volume du cube de côté $c-\varepsilon$ en dimension p : $(c-\varepsilon)^p$

Rapport volume des 2 cubes
($c=1$ et $\varepsilon=0,1$) :

p	1	2	4	8	16	20	30	40
$V_{c\varepsilon}/V_C$ (%)	90	81	66	43	18	12	4	1,5



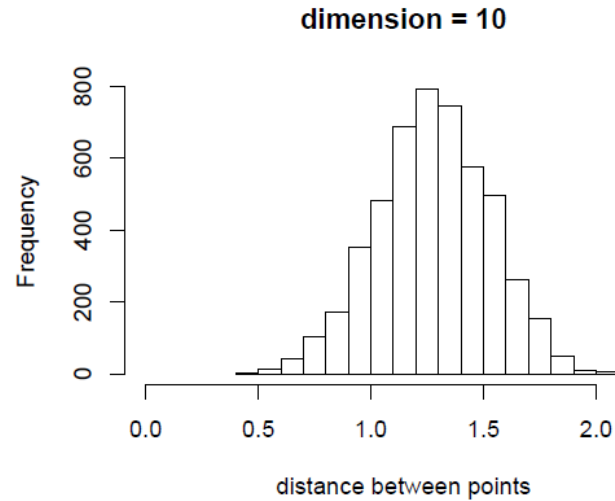



Vol(cube côté 0,9) / Vol(cube côté 1)

En grande dimension, tout le volume est dans l' « écorce »

=> Warning : la réduction du domaine de variations des paramètres a posteriori peut rendre les calculs déjà réalisés inutilisables

CONCENTRATION DES DISTANCES




Histogrammes des distances 2 à 2 pour 100 points uniformément répartis dans $[0,1]^p$


CURIOSITÉS DE LA MONTÉE EN DIMENSION

À quoi pourrait ressembler un hypercube en grande dimension ?


Dimension 3 :
8 sommets




Dimension 4 :
16 sommets



Dimension 5 :
32 sommets



Dimension 12 :
4096 sommets



Ces espaces sont « étranges », peu intuitifs et essentiellement vides !

⇒ Ne pas espérer capturer des phénomènes locaux

⇒ Tout le volume est dans les piques




Exploration « optimale » d'un domaine hypercubique

Placer des points dans le domaine des entrées $\mathbf{X} \in \mathbb{R}^p$ dans le but de « maximiser » la quantité d'information sur la sortie du modèle $Y = G(\mathbf{X})$

La précision (et donc le coût) de l'exploration dépend de p
(contrairement à la prop. d'incert.)

Grille régulière à n niveaux $\rightarrow N = n^p$ simulations

Ex: $p = 2, n = 3$
 $\rightarrow N = 9$
 $p = 10, n = 3$
 $\rightarrow N = 59049$





fléau de la dimension

Pour minimiser N , on a besoin d'échantillons assurant une bonne couverture de l'espace des entrées

Un échantillon purement aléatoire (Monte Carlo) ne le permet pas

Ex: $p = 2$
 $N = 10$

Monte Carlo



Plan optimisé

PLAN

- **Propriétés attendues**
- Suite à discrédance faible
- Plan hypercube latin (LHS)

PROPRIÉTÉS ATTENDUES ET RECHERCHÉES

1. **Couverture optimale de l'espace des paramètres d'entrée**
2. Robustesse en sous-projections
3. Séquentialité

PROPRIÉTÉ 1 : COUVERTURE OPTIMALE DE L'ESPACE


- Répartir « régulièrement » un certain nombre de points N dans l'espace p -dimensionnel des entrées ($\mathbf{X} \in \chi \subset \mathbb{R}^p$), pour construire le plan

$$D_N = \left(x_j^{(i)} \right)_{i=1 \dots N, j=1 \dots p}$$

- Dans la pratique en analyse d'incertitudes : $N \sim 10$ à 1000 et $p \sim 2$ à 50
- Echantillons assurant une bonne couverture de l'espace des entrées
- De plus : besoin de robustesse de cette répartition vis-à-vis de la réduction de dimension car souvent, ce sont les effets d'ordre faible qui sont influents
- Quelles sont les « bonnes » répartitions ? Différents critères possibles...


PROPRIÉTÉ 1 : COUVERTURE OPTIMALE DE L'ESPACE

◆ Exemple : $p = 2$ dimensions, $N = 10$ points.



x_1
* $N = 8$

Monte Carlo




x_1
* $N = 8$

Plan optimisé


◆ Question : qu'est-ce qui est optimisé à droite ?

PROPRIÉTÉ 1 : COUVERTURE OPTIMALE DE L'ESPACE

◆ Exemple : $p = 2$ dimensions, $N = 10$ points.



Monte Carlo



Plan optimisé

◆ Question : qu'est-ce qui est optimisé à droite ?

◆ Réponse : il n'y a pas de points « trop proches ».

PROPRIÉTÉ 1 : CRITÈRES GÉOMÉTRIQUES


◆ **Minimax design** D_{mM} : Minimise la distance maximale entre un point du domaine et un point du plan :

$$\min_D \max_x d(x, D)$$

$$\text{où } d(x, D) = \min_{y \in D} d(x, y)$$

[Johnson et al. 1990]
[Koehler & Owen 1996]

Aucun point du domaine $[0,1]^p$ n'est trop loin d'un point du plan D_{mM}




Un des meilleurs plans mais trop coûteux à construire pour $p > 3$.

Plans minimax

► $p = 1$; $X_i = (2i-1)/(2N)$; $\phi_{mM} = 1 / 2N$


► $p > 1$: recouvrement de sphères



PROPRIÉTÉ 1 : CRITÈRES GÉOMÉTRIQUES

- **Distance mindist :** $\phi(D^N) = \min_{x, y \in D^N} d(x, y)$ (norme L_2 usuellement)
- **Maximin design D_{Mm} :** maximise la distance minimale entre les points du plan

$$\max_{D^N} \min_{x, y \in D^N} d(x, y)$$




PLAN MAXIMIN


► $p = 1$; $X_i = (i-1)/(N-1)$; $\phi_{Mm} = 1 / (N-1)$

[minimax : $X_i = (2i-1)/(2N)$; $\phi_{mM} = 1 / 2N$]

► $p > 1$: empilage de sphères



[www.spacefillingdesigns.nl]



[www.packomania.com]


PROPRIÉTÉ 1 : CRITÈRE DE DISCRÉPANCE

Discrépance : critère statistique qui mesure la **dévi**ation maximale entre la répartition des points de l'échantillon et une **répartition uniforme**

Interprétation géométrique : Comparaison entre volume des intervalles du domaine et nbre de pts contenus dans ces intervalles

$$Q(\mathbf{t}) \subset \chi = [0,1[^p, Q(\mathbf{t}) = [0, t_1[\times [0, t_2[\times \dots \times [0, t_p[$$

$$\text{discrépance}(\text{plan}) = \sup_{Q(\mathbf{t}) \in [0,1[^p} \left| \frac{N_{Q(\mathbf{t})}}{N} - \prod_{i=1}^p t_i \right|$$



Discrépance faible = *bonne répartition uniforme des points dans l'espace, distribution régulière*

PROPRIÉTÉ 1 : CRITÈRE DE DISCRÉPANCE

Discrépance : critère statistique qui mesure la **dévi**ation maximale entre la répartition des points de l'échantillon et une **répartition uniforme**

Soit D_n la suite de points $\{x_1, \dots, x_n\}$ en dimension 1, répartis sur $[0,1]$
Si l'on considère la fonction de répartition empirique F_n , on peut définir la discrépance par :


Avec F_U la fonction de répartition de la loi uniforme sur $[0,1]$

Une suite est uniformément répartie sur $[0,1]^p$ si $\lim_{n \rightarrow \infty} \text{Disc}(D_n) = 0$

Suite Monte-Carlo « pur » : $D_n \sim 1/\sqrt{n}$

En pratique, choix permettant de faire des calculs : **discrépance L^2**

$$D_2^*(\Xi^N) = \left[\int_{[0,1]^p} \left[\frac{1}{N} \sum_{i=1}^N 1_{\mathbf{x}^{(i)} \in Q(\mathbf{t})} - \text{Volume}(Q(\mathbf{t})) \right]^2 d\mathbf{t} \right]^{1/2}$$



Discrépances L_2

Plusieurs définitions, dépendant de la norme et des intervalles considérés

$$D^*(\Xi^N) = \sup_{\mathbf{t} \in [0,1]^p} \left| \frac{1}{N} \sum_{i=1}^N 1_{\mathbf{x}^{(i)} \in Q(\mathbf{t})} - \text{Volume}(Q(\mathbf{t})) \right|$$

Choix permettant de faciliter les calculs : discrédance L^2

[Hickernell 1998]

Discrédance L_2 à l'origine :
$$D_2^*(\Xi^N) = \left[\int_{[0,1]^p} \left[\frac{1}{N} \sum_{i=1}^N 1_{\mathbf{x}^{(i)} \in Q(\mathbf{t})} - \text{Volume}(Q(\mathbf{t})) \right]^2 d\mathbf{t} \right]^{1/2}$$


Une propriété manquante : prise en compte de l'uniformité des projections des points sur des sous-espaces de $[0,1]^p$

=> **Discrédance L_2 modifiée**

$$D_2(\Xi^N) = \left[\sum_{u \neq \emptyset} \int_{C^u} \left[\frac{1}{N} \sum_{i=1}^N 1_{\mathbf{x}_u^{(i)} \in Q_u(\mathbf{t})} - \text{Volume}(Q_u(\mathbf{t})) \right]^2 d\mathbf{t} \right]$$

avec $u \subset \{1, \dots, p\}$

et $Q_u(\mathbf{t})$ la projection de $Q(\mathbf{t})$ sur C^u (cube unité de coordonnées dans u)




Calculs de la discr pance en pratique

- Discr pance L_2 centr e (intervalles anc r s en un sommet de l'hypercube)



Formule analytique :

$$C^2(\Xi^N) = \left(\frac{13}{12}\right)^p - \frac{2}{N} \sum_{i=1}^N \prod_{k=1}^p \left(1 + \frac{1}{2} \left|x_k^{(i)} - \frac{1}{2}\right| - \frac{1}{2} \left|x_k^{(i)} - \frac{1}{2}\right|^2\right) + \frac{1}{N^2} \sum_{i,j=1}^N \prod_{k=1}^p \left(1 + \frac{1}{2} \left|x_k^{(i)} - \frac{1}{2}\right| + \frac{1}{2} \left|x_k^{(j)} - \frac{1}{2}\right| - \frac{1}{2} \left|x_k^{(i)} - x_k^{(j)}\right|\right)$$



- Discr pance L_2 wrap-around (supprime les effets de bord en enveloppant le cube unit )

$$W^2(\Xi^N) = \left(\frac{4}{3}\right)^p + \frac{1}{N^2} \sum_{i,j=1}^N \prod_{k=1}^p \left[\frac{3}{2} - \left|x_k^{(i)} - x_k^{(j)}\right| \left(1 - \left|x_k^{(i)} - x_k^{(j)}\right|\right)\right]$$



LIEN ENTRE DISCRÉPANCE ET CALCUL D'UNE INTÉGRALE

Objectif : estimer une intégrale :

$$I = \int G(x) dx$$

Estimateur Monte-Carlo :

$$I_N^{\text{MC}} = \frac{1}{N} \sum_{i=1}^N G(x^{(i)})$$

où $x^{(i)}$ sont i.i.d. dans $[0,1]^p$

Propriétés de l'estimateur :

$$\mathbb{E}(I_N^{\text{MC}}) = I \quad \text{Var}(I_N^{\text{MC}}) = \frac{\text{Var}(G)}{N} \quad \varepsilon = O\left(\frac{1}{\sqrt{N}}\right)$$

Propriété générale (Koksma-Hlawka) :

$$\varepsilon \leq V(G) \text{disc}(D)$$

Avec une suite à faible discrédance D (quasi-Monte Carlo) : $\varepsilon = O\left(\frac{(\ln N)^p}{N}\right)$

Une suite est uniformément répartie sur $[0,1]^p$ si $\lim_{n \rightarrow \infty} \text{Disc}(D_n) = 0$

Choix bien connus : suite de Sobol', Halton, Faure, ...

PROPRIÉTÉS ATTENDUES ET RECHERCHÉES

1. Couverture optimale de l'espace des paramètres d'entrée
- 2. Robustesse en sous-projections**
3. Séquentialité




PROPRIÉTÉ 2 : ROBUSTESSE EN SOUS-PROJECTIONS

Le code de calcul $G(\mathbf{X})$ a souvent de faibles dimensions effectives :

- au sens de la troncature (nombre de variables influentes $\ll p$)
- au sens de la superposition (+ **gd ordre d'interaction influente $\ll p$**)

Il est donc nécessaire que le SFD conserve les propriétés space-filling sur les sous-espace de faibles dimensions (par importance : en dimension $p'=1$, puis $p'=2$, ...)

- $p' = 1$ – Bonnes projections 1D



Question : Quel plan a de bonnes projections 1D ?

- $p' \geq 2$ - Les discrédances L^2 modifiées (centrée, wrap-around, ...) prennent en compte les sous-projections dans leurs définitions

Par contre, les critères de distances vus précédemment n'assurent pas de robustesse en sous-projections

PROPRIÉTÉS ATTENDUES ET RECHERCHÉES

1. Couverture optimale de l'espace des paramètres d'entrée
2. Robustesse en sous-projections
- 3. Séquentialité**


PROPRIÉTÉ 3 : SÉQUENTIALITÉ DU PLAN

- Commencer par un plan de taille réduite (ex : taille 10)
- Augmenter la taille du plan en recyclant les calculs précédents

Exemple : suite de Sobol

On rajoute 2 points

On rajoute 2 points



PLAN

- Propriétés attendues
- **Suite à discrédance faible**
- Plan hypercube latin (LHS)

CONSTRUCTION D'UNE SUITE À DISCRÉPANCE FAIBLE

Séquence 1D de Van der Corput en base $b = 2$

Base b : $i = (... a_4 a_3 a_2 a_1 a_0)_b$


Syst. décimal : $i = \sum_{j=0}^m a_j b^j, 0 \leq a_j \leq b - 1$



$y = (0. a_0 a_1 a_2 a_3 \dots)_b$

Syst. décimal : $h(i, b) = \sum_{j=0}^m a_j b^{-j-1}$







i	binary form of i	radical inverse	x_i
0	0	0.0	0
1	1	0.1	0.5
2	10	0.01	0.25
3	11	0.11	0.75
4	100	0.001	0.125
5	101	0.101	0.625
6	110	0.011	0.375



Suite de Halton (dimension p) : pour chaque dimension, prendre une base (nombre premier) différente : $\{h(i, 2), h(i, 3), \dots, h(i, b_p)\}$

EXEMPLES 2D



Suite de Sobol vs. échantillon aléatoire vs. grille



EXEMPLES 2D

Suites à discrédance faible



dimension $p = 8$



EXEMPLES 2D

Suites à discrédance faible



dimension $p = 8$



EXEMPLES 2D

Suites à discrédance faible

Pathologies sur les projections 2D
=> Manque de robustesse dans les sous-projections



SUITES À DISCRÉPANCE FAIBLE

Comment choisir une séquence ?

- Plus la base est petite, plus la discrépance est petite.
- Choix par défaut : Sobol (sauf si on a de bonnes raisons de faire autrement).
- Si on veut plus de points, on utilise les points suivants dans la séquence : séquentialité
- Mettre les variables les plus importantes en premier.
 - Premières composantes utilisent une base plus petite (Halton), ou un polynôme irréductible de degré plus petit (Sobol, Nieder.).
 - Les variables importantes ont de meilleures projections 1D, 2D, ...


Nom	Base
Halton	$b(1), b(2), \dots, b(p)$
Sobol	$b=2$
Faure	Plus petit $b \geq p$
Niederreiter	$b \geq 2$, puissance d'un premier

SUITES (OU SÉQUENCES) À DISCRÉPANCE FAIBLE

Est-ce efficace ?

Pour l'intégration : souvent proche de $1/N$ pour $p < 40$.

Exemple : fonction d'Ishigami, dimension 3.



PLAN

- Propriétés attendues
- Suite à discrédence faible
- **Plan hypercube latin (LHS)**

PLANS HYPERCUBE LATINS (LHS)


[McKay et al. 1979]

Souvent, seules quelques variables sont influentes

Propriété : Projections uniforme sur les marginales

Principe : p variables, N points $\Rightarrow LHS(p, N)$

- On divise chaque dimension en N intervalles
- Tirage aléatoire d'un point dans chaque strate



Exemple : $p=2$, $N=4$

Chacun des niveaux est pris une seule fois par chaque facteur : **chacune des colonnes du plan est donc une permutation de $\{1, 2, \dots, N\}$**

PLANS HYPERCUBE LATINS (LHS)



Plans LHS : algorithme LHS(P,N) – méthode de Stein

```
ran = matrix(runif(N*p),nrow=N,ncol=p) #tirage de N x p valeurs selon loi U[0,1]
x = matrix(0,nrow=N,ncol=p)           # construction de la matrice x
```


```
for (i in 1:p) {
  idx = sample(1:N) #vecteur de permutations des entiers {1,2,...,N}
  P = (idx-ran[,i]) / N      # vecteur de probabilités
  x[,i] <- quantile_selon_la_loi (P)  }
```

Exemple : $p=2$, $N=10$, $X_1 \sim U[0,1]$, $X_2 \sim N(0,1)$

Monte Carlo




LHS



PLANS HYPERCUBE LATINS (LHS)

[McKay et al. 1979]




Quel est le meilleur plan d'expérience ?

- Gauche
- Centre
- Droit

PLANS HYPERCUBE LATINS (LHS)

[McKay et al. 1979]



Quel est le meilleur plan d'expérience ?

- Gauche : certains points sont trop proches
- **Centre : bon remplissage**
- Droit : $X_2 = X_1$!

Choix du LHS par optimisation de différents critères

- Remplissage
- Indépendance
- Uniformité


PLANS LHS OPTIMISÉS => SPACE-FILLING LHS

Méthode simple : générer un grand nombre (par ex. 1000) de LHS différents. Puis, choisir le meilleur au sens d'un critère $f(.)$ (« space filling »)


MAIS : le nombre de LHS possibles est énorme : $(N!)^p$

Méthode par algos d'optimisation (ex : minimisation de $f(.)$ par recuit simulé) :

1. Initialisation d'un plan X (LHS initial) et d'une température T
2. Tant que $T > 0$:
 1. générer un voisin X_{new} de X (voisin = permutation de 2 composantes dans une colonne)
 2. remplacer X par X_{new} avec la probabilité $\min\left(\exp\left[-\frac{\phi(\Xi_{\text{new}}) - \phi(\Xi)}{T}\right], 1\right)$
 3. faire décroître T (par ex. profil géom. : $T = T_0 c^i$ où $0 < c < 1$ et i n° d'itération)




3. Critère d'arrêt => X contient la solution optimale générée par le recuit simulé




Maximin LHS

Exemple :
LHS(2,16)




LHS à faible discrédance


Exemples



Maximin LHS
 $p=2$; $N=7$



Maximin LHS
 $p=2$; $N=16$



LHS à discr p. faible
 $p=2$; $N=16$

Sur des tests num riques ($N=100$), on voit qu'  partir de la dimension 10, le LHS maximin se comporte comme un LHS standard (dimension 40 pour un LHS   discr pance centr e faible)

Cela confirme la pertinence de la discr pance L^2 centr e en terme de sous-projection

En pratique, par exemple, on peut lancer plusieurs (~ 10) optimisations suivant un crit re de discr pance, et on compare les r sultats suivant un crit re de distance afin de choisir le meilleur plan

SYNTHÈSE

Enjeu : Échantillonner un espace de grande dimension de manière « optimale » (obtenir le plus d'informations possible sur le comportement de la sortie $Z / X \in \mathbb{R}^p$)

Problème : un échantillon aléatoire pur (Monte Carlo) remplit mal l'espace

1. Plans « space filling » sont de bons candidats pour bien remplir l'espace :

- Basés sur un critère de distances entre les points du plan (minimax, maximin, ...), *justification théorique pour la construction du métamodèle de krigeage*
- Basés sur un critère de répartition uniforme des points (discrépance) ; *justification théorique lorsque l'on calcule la moyenne de la fonction $G(X)$*

2. Propriété de projections uniformes sur les marges peut être obtenue via les plans hypercubes latins (LHS)

3. Il est possible de coupler les 2 propriétés en construisant des LHS optimisés

RÉCAPITULATIF

	Motifs, alignement	Plan séquentiel	Réduction dimension
Monte Carlo	Non	Oui	Oui
Faure, Halton, Sobol	Oui, en dim. élevée	Oui	Oui, mais pathologies
LHS à discrétion centrée faible	Non	Non	Oui
LHS maximin	Oui	Non	Non

Crédits & Bibliographie

Ouvrages :

- Faivre et al., *Analyse de sensibilité et exploration de modèles – Applications aux sciences de la nature et de l'environnement*, Editions Quaé, 2013.
- Fang et al., *Design and modeling for computer experiments*, Chapman & Hall, 2006
- C. Lemieux, *Monte Carlo and Quasi-Monte Carlo Sampling*, Springer-Verlag, 2009
- S. Da Veiga, F. Gamboa, B. Iooss and C. Prieur. *Basics and trends in sensitivity analysis - Theory and practice in R*, SIAM, 2021

Articles :

- G. Damblin, M. Couplet & B. Iooss, Numerical studies of space filling designs: optimization algorithms and subprojection properties, *Journal of Simulation*, 7, 2013
- Koehler, J. and Owen, A. Computer experiments. In Ghosh, S. and Rao, C., editors, *Design and Analysis of experiments*, volume 13 of *Handbook of statistics*. Elsevier, 1996
- McKay, M., Beckman, R., and Conover, W. A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, 21, 1979
- L. Pronzato & W. Müller. Design of computer experiments: space filling and beyond. *Statistics and Computing*, 22, 2012